GPU/服务器资源调度项目

阶段性访谈分析报告

三份真实录音的需求获取证据整理

报告定位：本报告用于软件需求工程课程第 6 周第一次检查，整理 2026 年 10 月 20 日完成的三次半结构化访谈。报告给出阶段性事实、假设验证和候选需求，不将尚未验证的观点写成最终需求基线。

课程	软件需求工程（2026 秋）
项目	面向科研实验室的 GPU/服务器资源申请与公平调度系统
团队成员	徐天成、刘明桥
访谈样本	3 名实验室 GPU 高频使用者，其中包含 1 名较新成员
录音总时长	约 29 分 45 秒
报告版本	v1.0，2026-10-20
匿名规则	正文仅使用 `INT-01`、`INT-02`、`INT-03`

说明：原始录音文件单独保存，不在本报告中披露姓名、账号、服务器地址或敏感项目名称。自动转写仅用于辅助整理，所有结论均回到录音时间戳核验；无法可靠识别的内容不作为证据。

1 结论摘要

三次访谈共同表明，实验室已经使用 Slurm 队列解决了一部分“抢卡”和空占问题，因此项目不应重复开发底层调度器。真正未被充分解决的是：**预计等待与完成时间不清楚、申请信息过少、冲突依赖人际协调、异常或人工操作缺少及时通知，以及公平规则难以同时兼顾短任务、长任务和紧急任务。**

本轮得到七项阶段性结论：

1. **Slurm 是现状基础设施。**三位受访者均通过 Slurm、`nvidia-smi` 或相关命令判断资源状态，系统方案应作为 Slurm 之上的申请、解释、通知和协同层。
2. **“看得到队列”不等于“知道要等多久”。**受访者仍希望知道前方任务数量、预计剩余时间和自己的大致启动时间；可接受等待上限因人和场景而异，从约 1 小时到 12 小时不等。
3. **纯手工登记曾失败。**已有资源使用表因成员不持续填写、维护成本高而停用；另一种按时段预约的表格还出现“占了时段但没有实际用卡”的问题。
4. **固定平均配额缺少支持。**两名受访者明确认为任务规模差异大，简单按人平均 GPU 小时不合适；更可接受的是等待时间、任务时长和必要性共同参与排序。
5. **任务能否中断是关键属性。**调试、验证类任务被认为不宜中断，而可重复的批处理任务更容易让出资源。直接自动终止任务存在较高风险。
6. **冲突处理主要依赖同伴协商。**当前缺少明确的审批者和统一证据标准。受访者通常接受“真正紧急”的任务优先，但希望说明原因，反对无解释的停任务或插队。
7. **异常通知和责任识别有真实证据。**存在容器被误停后排查半天的经历；服务器不可用时，用户希望收到邮件或其他明确通知。

结论边界：三位受访者均为同一实验室内的高频 GPU 使用者，尚未覆盖正式服务器管理员、老师和低频用户；单场访谈约 9–10 分钟，未完整执行原计划的 40–45 分钟问题清单，也未使用公平情景卡。因此，本报告可作为第一次检查的真实需求获取证据，但不能单独构成最终需求基线。

2 研究方法与证据处理

2.1 访谈实施

三次访谈均在 2026 年 10 月 20 日进行，采用同一份半结构化问题清单。开头说明课程用途、匿名原则、可跳过问题和可随时停止，并取得录音同意。实际访谈重点覆盖：使用背景、最近一次用卡经历、现行规则、等待与冲突、公平与配额、异常中断、通知和系统期望。

编号	时长	角色概括	使用特征	代表性经历
INT-01	10:13	研二，高频普通用户	几乎每天；推理优化；常用 4/8 卡	长队列导致放弃；容器曾被误停
INT-02	10:13	高年级高频用户，偶尔协助权限	几乎每天；推理任务；常用 8 卡	旧登记表停用；先到先得导致队列集中
INT-03	09:19	研一/较新成员，高频用户	每天；推理任务；常用 8 卡	预约空占；现有短任务优先与等待保护

2.2 转写、校正与引用规则

录音先由本地 Whisper 模型生成带时间戳的初稿，再结合项目术语进行人工语义校正，例如将近音识别统一为 Slurm、AMD、H200、Docker、`nvidia-smi`。证据编号采用“访谈编号 + 时间戳”，例如 `INT-01/00:57--01:13`。报告遵循以下规则：

- 只有语义清楚且能由录音定位的内容才进入证据表；
- 技术型号无法完全确认时，只保留对需求分析有意义的上位概念；

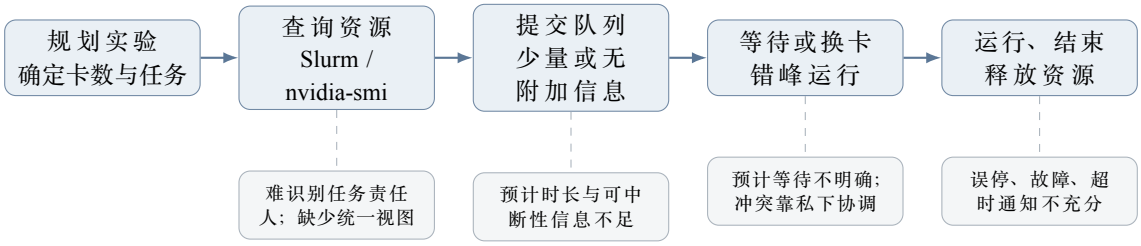
- 受访者没有回答或回答含糊的问题标为“未知”，不根据常识补全；
- 归纳结论至少区分单人证据、多源证据和研究者推论。

2.3 证据强度

本报告将证据分为三档：**强**表示至少两位受访者提供了相互印证的具体经历；**中**表示一位受访者有清楚的具体经历，或多人表达了相似观点但缺少行为证据；**弱**表示只有方案偏好、假设性回答或仍需回访确认的内容。

3 当前工作流程与系统边界

三次访谈反映的现状流程如下。流程中 Slurm 已承担排队和部分优先级调度，但申请解释、预计等待、人工协调、异常通知和规则治理仍散落在命令行、口头沟通和微信中。



据此，课程项目的合理边界是：**不实现 GPU 驱动或替代 Slurm 调度器，而是提供结构化申请、状态解释、策略配置、通知、审计和原型化调度比较。**系统应尽量读取 Slurm 和监控数据，避免要求用户重复维护一张独立表格。

4 单次访谈记录

4.1 INT-01：高频推理用户

背景。研二，在实验室一年多，几乎每天使用 GPU，主要进行模型推理优化，常见任务需要 4 张或 8 张卡。

最近经历。受访者计划使用一组 AMD GPU，但发现队列中已有十多个任务，预计需要等待十多个小时，最终放弃该资源。过去通过在实验室口头询问判断资源，信息不够准确；部署 Slurm 后，可以通过命令查看队列，准确性明显改善。

规则与公平。受访者认为当前明确规则主要是任务必须通过 Slurm 提交。其个人会主动选择使用人数较少、性能稍弱的资源，并把实验拆成较短任务以降低对他人的影响。对于固定 GPU 小时配额持反对态度，理由是不同任务需求差异较大。

异常证据。早期曾有 Docker 容器被他人误停。由于没有收到通知，受访者先按机器故障排查，约半天后才通过日志确认是人工停止。该经历直接支持任务所有权标识、人工操作通知和审计记录。

需求线索。希望看到前方任务预计剩余时间和自己的大致启动时间；建议队列考虑任务时长，短任务可获得较高优先级；任务超过预计时长时应被识别。但“直接自动杀掉”只能视为受访者建议，仍需管理员和安全性评审。

4.2 INT-02：高频用户与轻量权限协助者

背景。高年级学生，几乎每天运行推理任务，常用 8 卡；偶尔有人向其询问服务器权限，但其不是正式硬件管理员。

现行流程。在没有辅助工具时，较难从服务器进程准确判断任务所有者；使用 Slurm 后能够看到任务发起者。实验室曾维护 GPU 资源使用列表，要求填写任务说明和预计时长，但成员逐渐不填写，且表格维护困难，最终停用。

等待与任务差异。典型等待约半小时到一小时，会打断工作节奏但通常不直接影响总进度。调试任务被认为不适合中断，可重复的批处理任务相对适合让出资源。受访者承认会为时长估计留出缓冲，说明申报值并不等于真实运行时长。

公平与紧急任务。受访者认为当前大体采用先到先得，但单个用户连续提交大量任务可能让服务器一整天都满载；固定配额又可能压制计算量本来较大的任务。其接受毕业或截止任务优先，但强调应先说明任务和理由，不能无解释地停止他人任务。

需求线索。希望系统对紧急任务提供受控优先处理，并显示大致完成时间；预计时长仍应由申请人填写，系统可基于历史数据辅助，但不应假装能精确预测。

4.3 INT-03：较新成员与高频用户

背景。研一/较新成员，入组约一年，日常进行推理类任务，常用多卡资源。

流程演化。过去使用预约表时，出现用户占用时间段但没有实际使用 GPU、其他人又无法使用的情况；切换到 Slurm 队列后，该问题得到缓解，受访者认为 GPU 利用率较高。当前提交任务通常不要求填写额外申请信息。

现有调度认知。受访者认为队列机制相对公平，并提到实验室已经设置短任务优先和等待保护：时长较短的任务优先级较高，同时不能让任务无限等待。这说明原型 B 的部分规则在真实环境中已有雏形，可以作为比较基线，而不是从零假设。

异常与通知。当队列或服务器出现问题时，可能需要管理员权限恢复。受访者明确希望服务器不可用时收到邮件通知。其白天可接受等待约一小时，并希望知道前方还有多少任务。

新成员视角。遇到问题主要询问熟悉的同学，愿意使用面向新成员的规则说明和自助帮助。对任务时长及等待规则，受访者认为需要由人参与确认，而不是完全由机器决定。

5 跨访谈主题分析

5.1 主题一：状态透明的缺口已经从“有没有队列”转向“队列意味着什么”

Slurm 已能展示任务和排队顺序，但三位受访者仍缺少对等待的可行动解释。INT-01 因预计等待十多个小时而放弃；INT-02 和 INT-03 白天可接受的等待约一小时，超过后会暂停、换资源或转做其他工作。系统应提供区间估计和不确定性，而不是给出无法保证的精确时间。

5.2 主题二：低填写成本是系统采纳的前置条件

两段独立经历表明，纯手工表格不可靠：一类表格因无人持续填写而停用，另一类预约表产生“占位但未使用”。因此，任务状态、实际开始时间、结束时间和资源占用应优先从 Slurm 自动同步；用户只补充系统无法获得的少量信息，如任务目的类别、截止时间、可中断性和联系人。

5.3 主题三：公平不是平均分，而是可说明的情境化规则

受访者并不支持简单平均配额，也不完全满意纯先到先得。现有偏好包括：短任务适度优先、等待时间增长后提升优先级、真正紧急任务可优先、不同任务规模应区别处理。这些规则存在相互冲突，需要在原型中通过具体场景验证，而不能直接汇总为一个不透明的总分。

5.4 主题四：自动化必须识别任务可中断性

调试和关键验证任务被认为不宜中断，可重复计算任务更适合让出资源。若系统只根据超时直接终止任务，可能造成难以恢复的实验损失。更稳妥的流程是“提醒 - 宽限期 - 用户确认 - 必要时管理员处理”，并记录中断原因和操作者。

5.5 主题五：人际协调有效，但不可作为唯一治理机制

当前冲突通常由使用者私下协商，受访者也普遍愿意为真正紧急的任务让步。这种机制在小规模团队中成本较低，但依赖熟人关系和个人道德，无法保证一致性、可追踪性或对新成员的公平。系统应保留沟通空间，同时提供最小规则、理由和记录。

6 H1–H6 假设验证

假设	状态	证据强度	判断依据	关键来源
H1 状态/排队不透明	支持	强	Slurm 已改善“有没有任务”的可见性，但预计剩余时间、前方任务数量和大致启动时间仍不足；出现长等待后直接放弃。	INT-01、02、03
H2 需求/时长估不准	部分支持	中	用户会自行留缓冲；申请时长可能明显大于实际运行；受访者认为时长应由人填写、系统只能辅助。尚无时长误差统计。	INT-02、03
H3 紧急任务靠人工且可能滥用	部分支持	中	有毕业补实验临时优先的实例，主要靠口头说明和同伴理解；受访者接受有理由的加急，但未发现滥用案例。	INT-01、02、03
H4 长任务/提前结束/维护影响他人	部分支持	强	存在预约空占、连续大量任务占满白天、任务中断和服务器不可用等证据；但提前释放和维护流程尚未系统调查。	INT-01、02、03
H5 人工调整无依据/无记录	证据不足	中	发现误停容器、无通知和依靠日志追查的风险；但尚未取得管理员正式调整队列、审批和申诉流程的直接证据。	INT-01
H6 公平定义不一致	支持	强	固定配额被质疑，先到先得被认为“相对合理但有缺陷”，短任务优先、等待保护和紧急任务又获得不同程度支持。	INT-01、02、03

假设修订建议：将 H1 从“资源状态完全不透明”修订为“现有队列能够展示状态，但缺少预计等待、任务责任和排序解释”；将 H5 保留为待验证假设，不应在第一次检查中写成已证实事实。

7 候选需求与证据追踪

以下需求均为候选项，状态为“待评审”，不能直接视为需求基线。优先级综合考虑证据强度、用户影响和原型验证价值。

编号	候选需求	优先级	置信度	来源
CAND-01	系统应从 Slurm/监控接口同步 GPU 状态、任务状态、实际开始时间和占用情况，避免重复维护独立表格。	P1	高	INT-01/01:22；INT-02/02:26；INT-03/02:00
CAND-02	系统应展示排队位置、前方任务数量、预计启动时间区间及估计置信度；估计变化时更新。	P1	高	INT-01/07:23；INT-02/07:20；INT-03/06:43
CAND-03	申请只要求填写系统无法自动获取的最小信息：预计时长、任务类型、可中断性、截止时间/紧急理由和匿名联系人。	P1	中	INT-01/09:25；INT-02/09:15；INT-03/08:45
CAND-04	用户应能标记任务是否可中断/是否有 checkpoint；调度规则应区分调试、验证和可重复批处理任务。	P1	高	INT-01/03:22；INT-02/04:22；INT-03/03:39

编号	候选需求	优先级	置信度	来源
CAND-05	系统应在任务即将启动、超时、被调整、被中断以及服务器不可用时通知用户，并提供原因。	P1	高	INT-01/04:59；INT-03/06:03
CAND-06	调度策略应支持等待时间增长、短任务倾斜和资源匹配；固定平均配额不作为默认硬规则。	P1	高	INT-01/06:35；INT-02/06:37；INT-03/06:23
CAND-07	紧急任务申请应给出理由或证据，并向受影响用户展示可理解的调整原因；不允许无解释插队。	P2	中	INT-01/03:56；INT-02/05:06；INT-03/04:25
CAND-08	超过预计时长时，系统默认先提醒并给予宽限期；终止任务前应考虑可中断性，并由用户或管理员确认。	P1	中	INT-01/09:42；INT-02/04:22；INT-03/08:45
CAND-09	人工停止、调整或释放任务应记录操作者、时间和理由，并允许任务所有者查看相关记录。	P2	中	INT-01/04:59–05:34
CAND-10	系统应提供简短的规则说明、常见问题和新成员操作引导，并明确遇到权限或故障问题的联系渠道。	P2	中	INT-01/05:43；INT-03/08:19
CAND-11	系统应支持换用其他可接受 GPU、暂停/重新提交或继续等待等候补选择。	P2	中	INT-01/02:29；INT-02/07:20

8 对两个原型方案的影响

8.1 原型 A：轻量申请与透明先到先得

原型 A 仍可作为基线，但不应简单复刻曾经失败的共享表格。建议将其定义为“**Slurm 自动同步 + 极少字段 + 明确队列顺序**”：

- 自动读取资源与任务状态，用户只补充预计时长、可中断性和匿名联系方式；
- 以提交时间为主排序，展示前方任务和大致等待区间；
- 对任务超时、服务器离线和人工操作发送通知；
- 管理员调整时必须填写理由，但不计算复杂综合分数。

该方案主要验证：低填写成本是否能够避免旧表格失效；透明的先到先得加等待信息是否已足够满足多数场景。

8.2 原型 B：可解释的动态优先级与候补

访谈不支持把“每人固定平均配额”作为原型 B 的核心。更符合证据的初始因素是：

1. 等待时间及老化机制，防止任务无限等待；
2. 预计任务时长，对短任务适度倾斜但避免长任务饥饿；
3. 已说明理由的截止/紧急程度；
4. 资源匹配与任务可中断性。

配额可作为软约束或异常提醒，而不是简单的平均硬上限。排序结果必须展示主要原因；任何抢占或自动终止都应经过提醒、宽限和确认。该方案主要验证：复杂规则是否真的改善等待和利用率，以及用户能否理解并接受排序原因。

9 待补证问题与下一步计划

9.1 必须补充的利益相关者

1. **正式管理员/资源协调者**：核实 Slurm 现有配置、短任务优先和等待保护的真实规则；确认人工调整、故障处理、日志、通知及可提供的匿名数据。

比较维度	原型 A	原型 B
核心机制	申请时间为主，规则简单	等待老化、时长、紧急性、资源匹配综合
数据录入	最小字段，自动同步	需额外填写紧急理由、可中断性等
解释方式	展示顺序与人工调整理由	展示影响排序的主要因素和变化原因
关键风险	长任务或批量提交占据队列	规则复杂、可被策略性填写、长任务饥饿
访谈验证重点	是否足够透明、是否愿意持续填写	是否理解排序、是否接受紧急与短任务倾斜

2. **老师或项目负责人**：确认什么情况属于可接受的紧急任务，谁有权批准，以及项目目标、公平和科研产出之间如何权衡。
3. **低频或刚入组成员**：验证命令行门槛、规则发现、权限申请和自助引导需求，避免报告只代表熟练用户。

9.2 建议收集的第二类证据

本轮只有访谈证据。第一次检查前建议至少补充一类脱敏材料：

- Slurm 当前分区、优先级或提交规则说明；
- 旧预约表/登记表的字段截图及停用原因说明；
- 一周匿名队列样本：提交时间、开始时间、卡数、预计时长、实际时长、状态；
- 一次维护或故障通知样例，验证通知渠道和提前量。

9.3 回访问题

下一轮访谈应重点确认：预计等待如何计算才可信；短任务优先的阈值与老化规则；紧急任务所需证据；哪些任务可以抢占；超时后由谁确认；任务所有者信息公开到什么程度；旧表格为何无法持续维护。

10 关键证据索引

证据	时间戳	校正后的证据摘要	支持内容
E01	INT-01/00:57–01:13	AMD 队列中有十多个任务，预计等待十多个小时，受访者最终放弃使用。	H1、CAND-02
E02	INT-01/01:22–01:45	过去靠口头询问信息不准；使用 Slurm 后可查看队列，信息更可靠。	系统边界、CAND-01
E03	INT-01/04:59–05:34	Docker 容器被他人误停，受访者未收到通知，排查约半天后才从日志发现原因。	H5 风险、CAND-05/09
E04	INT-01/06:35–07:11	固定 GPU 小时配额被认为不适合不同任务，现状更多依靠协调与自律。	H6、CAND-06
E05	INT-01/07:23–08:03	最想知道前方任务预计剩余时间和何时轮到自己；可接受最长等待约 12 小时。	H1、CAND-02
E06	INT-02/01:29–01:47	常见等待约半小时到一小时，影响工作节奏但通常不直接影响总进度。	H1、等待场景
E07	INT-02/02:26–02:49	曾有任务登记表，但成员后来不再填写，且维护成本高，最终停用。	CAND-01/03/04
E08	INT-02/04:22–04:38	调试任务不宜中断，可重复的计算任务更容易让出资源。	H4、CAND-04/08
E09	INT-02/05:37–05:56	有毕业补实验的任务通过口头说明获得优先，依靠其他使用者理解和让步。	H3、CAND-07
E10	INT-02/06:37–07:07	先到先得可能因连续大量任务占满白天；固定配额也可能不适合重计算任务。	H6、CAND-06
E11	INT-03/02:00–02:34	预约表曾出现占时不用，其他人无法使用；改用 Slurm 队列后问题缓解。	H4、CAND-01
E12	INT-03/06:03–06:10	服务器不可用时，希望通过邮件收到明确通知。	CAND-05

证据	时间戳	校正后的证据摘要	支持内容
E13	INT-03/06:23–06:35	当前已有短任务优先和等待保护的规则，避免任务等待过久。	H6、原型 B
E14	INT-03/06:43–06:54	白天可接受等待约一小时，最想知道前方还有多少任务。	H1、CAND-02
E15	INT-03/08:19–08:31	较新成员希望系统提供使用说明和问题处理入口。	CAND-10

11 生成式 AI 使用与人工核验说明

本报告使用本地语音识别模型对三段真实录音生成初步转写，并使用生成式 AI 辅助归类、形成表格和排版。人工核验措施包括：逐段检查时间戳；结合访谈问题和领域术语校正明显近音错误；不把无法识别的型号、姓名或短句写入结论；所有需求均保留录音来源；将推论、受访者观点和已发生事实分开表述。

已知局限是自动转写对中英文混合术语、GPU 型号和低音量短答的识别不稳定。本报告没有生成虚构访谈、没有补造管理员意见，也没有把模拟数据描述为真实数据。正式纳入需求基线前，应由项目组再次抽听关键片段，并将匿名摘要发给受访者确认。

——报告结束——